ChatBot BILL

Bill es un asistente virtual diseñado para ayudar a los estudiantes en su preparación para el examen **Microsoft Certified: Azure AI Engineer Associate (AI-102)**.

Objetivo

El objetivo de **Bill** es ofrecer soporte en tiempo real para consultas sobre la guía de estudio y repasar temas para los estudiantes que se están preparando para el examen AI-102, mejorando la eficiencia y efectividad en su preparación.

Bill asistirá con la guía de estudio, repasando conceptos clave y respondiendo preguntas, facilitando así un apoyo integral durante el proceso de estudio.

Arquitectura

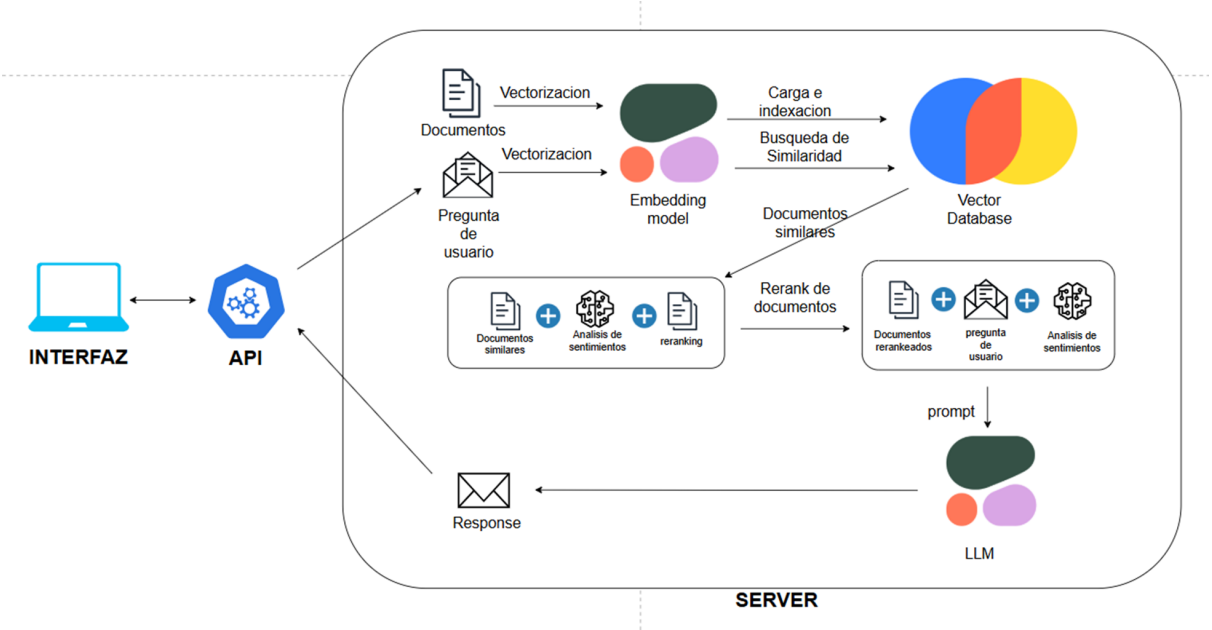

La arquitectura trabajada consta en 3 grandes bloques de funcionamiento que seran definidos a continuación:

- Interfaz
- Api
- Server

Interfaz

La interfaz de usuario está construida con Streamlit. Las funciones se localizan en el archivo `app.py` y se ejecuta con el comando:

```
streamlit run app.py
```

La interfaz de **Streamlit** proporciona un entorno interactivo y fácil de usar para la interacción con el chatbot.

API

La API está creada con FastAPI. Se encarga de manejar las consultas de los usuarios y generar las respuestas. El código se organiza en diferentes capas para mantener la modularidad y la claridad:

- **main**: Contiene la entrada a la API.
- **routers**: Define el endpoint POST que recibe una consulta del usuario (en formato de texto) y devuelve la respuesta.
- **models**: Define las clases de **Pydantic** que se utilizan para validar la entrada y salida de datos.
- **database**: Contiene las funciones para interactuar con la base de datos **ChromaDB** y **Cohere**.
- **app**: Contiene el código que maneja la interfaz de usuario en **Streamlit**.

se ejecuta con el comando:

```
uvicorn main:app --reload
```

Server y Arquitectura RAG

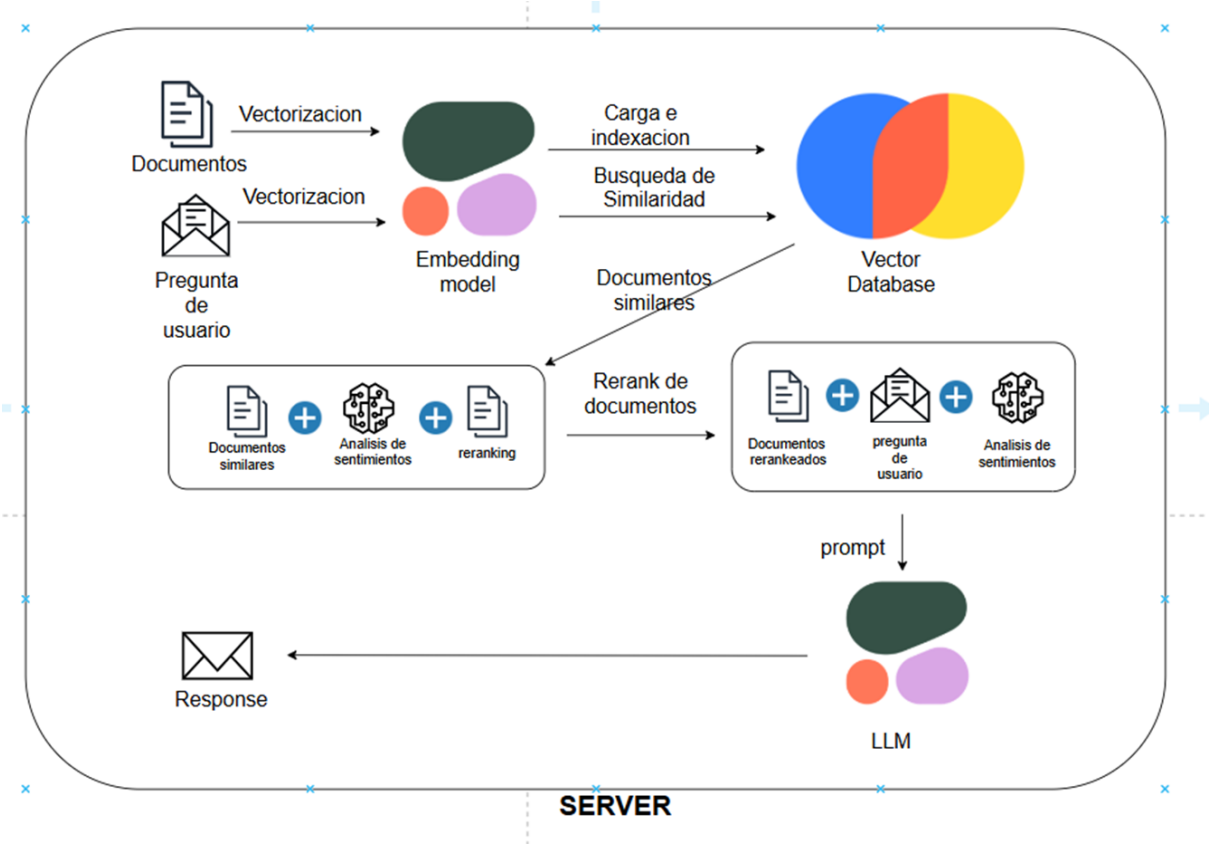

1. Preparación y Carga de Datos

En el archivo `load_database.py` se definieron las funciones:

- **Conexiones**:
  - `connect_cohere()`: Realiza la conexión a Cohere.
  - `connect_database()`: Realiza la conexión con la base de datos vectorial ChromaDB.
- **Crear Colección**:
  - `get_embeddings()`: Genera los embeddings de los textos con el modelo `embed-multilingual-v3.0` de Cohere, utilizando el input_type `search_document` que es el adecuado para vectorizar documentos de texto.
  - `MyEmbeddingFunction`: Implementación personalizada de la clase `EmbeddingFunction` de ChromaDB que utiliza la función `get_embeddings()` para convertir los textos en embeddings.
  - Se crea una instancia de cliente persistente pasándole como path la constante `PATH_CONEXION`.

    - Se crea una colección, se le pasa el nombre a través de una constante `COLLECTION_NAME`, se le asigna la función de embedding personalizada, y se especifica que el algoritmo a usar es el de similitud de coseno porque es el recomendado para realizar búsquedas de similaridad en textos.

- **Preparación de Datos**:
    - La información utilizada por **Bill** se extrajo de la guía de estudio oficial disponible en la página de Microsoft. Los módulos de la guía se cargaron en documentos PDF.
    - `read_pdf()`: Lee un archivo PDF y extrae todo el texto contenido en él.
    - `preparar_fragmentos_metadatos()`: Toma el texto extraído de un PDF y lo divide en fragmentos (chunks) de tamaño determinado. Además, agrega metadatos a cada fragmento para identificar el módulo o título del contenido. Los fragmentos se almacenan como una lista de diccionarios que contiene tanto el texto como los metadatos asociados.
    - Utiliza el **RecursiveCharacterTextSplitter** de **LangChain** para dividir el texto en fragmentos. Se eligieron los valores `chunk_size=2000` y `chunk_overlap=259` porque estos eran los valores adecuados para dividir el texto sin que se pierda el significado, asegurando que el contenido mantuviera la consistencia y no se interrumpieran ideas clave entre fragmentos.
- **Carga de Datos**:
    - **Definición de** `lista_pdfs`: Se crea un diccionario que asocia los títulos de los módulos con las rutas de los archivos PDF correspondientes.
    - Se inicializa la lista `all_chunks` vacía para almacenar los fragmentos de texto de todos los documentos. Luego, se itera sobre los elementos de `lista_pdfs` utilizando la función `read_pdf()`, que extrae el texto del archivo.
    - `preparar_fragmentos_metadatos()`: Divide el texto en fragmentos y añade el título del módulo como metadatos.
    - Se establece la conexión con la base de datos utilizando `connect_database()`, y luego se cargan todos los fragmentos de texto y sus metadatos a la colección de la base de datos vectorial.

2. Retrieve

- **get_query_embeddings()**: Convierte la entrada del usuario (consulta) en embeddings utilizando el modelo de embedding `embed-multilingual-v3.0` de **Cohere** con el parámetro `input_type="search_document"`, ya que este tipo de entrada está diseñado específicamente para búsquedas por similaridad.
- **get_documents()**: Toma la entrada del usuario, genera los embeddings correspondientes y realiza una búsqueda en la colección de **ChromaDB** para encontrar los documentos más relevantes basados en la similitud semántica.

3. Reader

- **classify_text()**: Clasifica la entrada del usuario según el sentimiento que transmite. Utiliza el modelo de clasificación multilingüe de **Cohere** y una serie de ejemplos predefinidos de diferentes sentimientos (positivo, negativo y neutral). La función devuelve la clasificación de la entrada, permitiendo determinar si el sentimiento de la consulta es positivo, negativo o neutral.
- **realizar_reranking()**: Realiza un reordenamiento de los documentos recuperados en función del sentimiento de la consulta. Si la clasificación de la entrada es "negativa", prioriza documentos que contengan soluciones mas detalladas, para mejorar la experiencia del usuario. Luego, usa el modelo de **Cohere** para realizar un reordenamiento (reranking) de los documentos según la relevancia.
- **rag_answer()**: Genera respuestas utilizando el enfoque **Retrieval-Augmented Generation** (RAG). Esta función toma como entrada una pregunta del usuario, clasifica el sentimiento de la consulta, realiza un reordenamiento de los documentos relevantes y luego genera una respuesta personalizada utilizando el modelo `command-r-plus-08-2024` de **Cohere**. Además, adapta el mensaje del sistema según el sentimiento detectado (positivo, negativo o neutral).
- **chatbot()**: Maneja las interacciones básicas con el usuario, como saludos y despedidas, antes de delegar las consultas más complejas a la función `rag_answer()`. Esta función responde con un saludo adecuado si la entrada es una de las frases predefinidas, y si no lo es, redirige la consulta a la función **RAG** para obtener una respuesta más compleja.